두바퀴 RAG 데이터 처리 과정

따릉이 상담 자료가 검색 가능한 근거가 되기까지

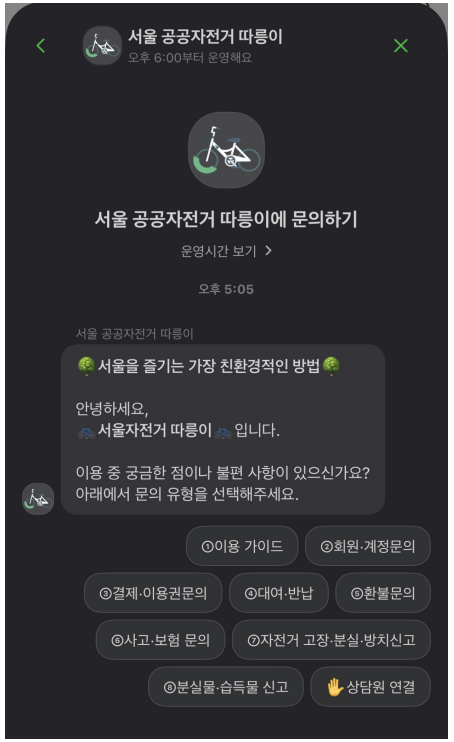
질문에 답하기 전, 관련 문서를 먼저 찾습니다.

데이터 수집 → 전처리 → 청킹 → 임베딩 → 저장·검색

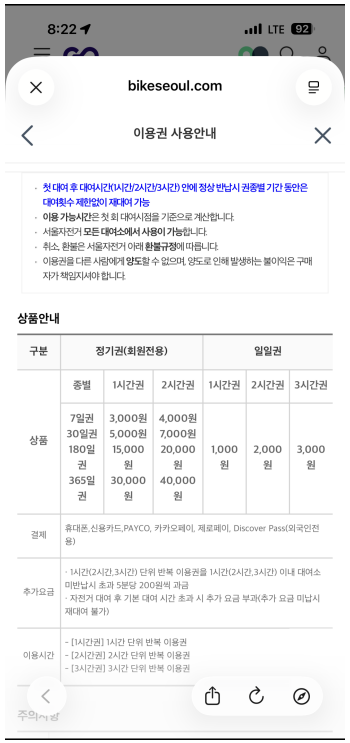
예: “반납이 안 돼요” → 반납 실패 안내를 검색 → 답변 근거로 활용

01 데이터 수집

앱 챗봇과 따릉이 공식 안내 화면을 참고했습니다



따릉이 앱 챗봇 화면



따릉이 공식 이용권 안내

수집한 자료

따릉이 앱 챗봇 FAQ
이용권·환불 등 공식 안내
서울시·서울시설공단 공개 자료
사진은 원본 근거로 보관

출처: 사용자 제공 캡처(bikeseoul.com), 서울시설공단 sisul.or.kr

02 수집 자료를 8개 주제로 정리

시민용 실제 안내와 프로젝트 교육용 가상 정책을 구분합니다

대여 안내
QR 대여, 대여 실패

반납 안내
반납 완료, 직접 반납

고장·사고
고장 신고, 보험 안내

요금·환불
이용권, 추가요금, 환불

계정·보안
가입·로그인, 보안 초동 안내

후속 문의
상담 및 문의 경로

담당자 정책 ① · 가상
이관 기준과 처리 경로

담당자 정책 ② · 가상
티켓 생성·처리 단계

03 전처리와 청킹

Codex로 주제별 문서를 정리하고 검색 단위로 나눴습니다

전처리

Codex로 주제별 Markdown 정리
실제 안내 / 가상 설정 구분
출처·접근 권한·버전·파일 해시 관리

청킹 기준

문서 제목 → ## 주제별 절
각 절 안에서 빈 줄로 문단 구분
문단을 하나씩 검색 조각으로 만듦

예시

반납 실패 → 잠금장치 확인 문단 → 직접반납 안내 문단

이웃 문단을 중복하지 않음: 오버랩 0자

실제 안내와 가상 설정이 섞이는 특정 문단은 분리합니다.

04 청킹 방식 비교

동일한 13개 질문과 임베딩·검색 설정으로 공개 자료를 비교했습니다

절 안의 문단 단위

전체 44개 중 공개 36개
기대 문서·절 상위 3개: 각각 13/13
실제 안내 / 가상 설정 분리

절 전체 단위

전체 41개 중 공개 33개
기대 문서·절 상위 3개: 각각 13/13
실제·가상 내용이 3개 절에서 혼합

해외 이용 질문(WF03): 두 방식 모두 검색 결과 없음

같은 질문에서 기대 절의 순위도 같았습니다. 두 방식의 차이를 판단하기에는 질문 수가 적습니다.

※ 직접 임베딩 API와 코사인 계산으로 비교; n8n 전체 실행이나 공식 판정은 아닙니다.

출처: runs/public/20261105-120437-chunk-retrieval-comparison/summary.json

05 임베딩과 유사도 검색

문서와 질문을 숫자로 바꿔 관련 내용을 찾습니다

문서 청크

"반납이 완료되지 않을 때"

시민 질문

"반납 알림이 안 와요"

→

같은 임베딩 모델

text-embedding-3-large
로컬 벡터 1개: 3,072차원

→

유사도 검색

코사인 유사도 비교
관련 문서 검색

로컬 시연 설정: 상위 5개 · 최소 점수 0.30. 모델별 성능 비교는 아직 하지 않았습니다.

06 저장·권한·복구

현재 저장 방식과 향후 계획

현재 · 메모리 저장

n8n Simple Vector Store
public / restricted 저장 공간 분리
시민: public · 허용 담당자: 둘 다
VM 수동 색인 44개·검색 시험 7건

향후 · 팀 VM 계획

Docker 기반 PostgreSQL에 영속 저장
pgvector 확장과 n8n 연동 검토
백업·복구와 권한 필터 시험 필요
아직 VM에 구현·검증하지 않음

모의 권한으로 검색 범위를 확인했으며 실제 사용자 조회와의 연결은 미시험입니다.

메모리는 재시작 시 사라질 수 있어 재색인과 복구 확인이 필요합니다.

07 로컬 시험 결과와 실제 예시

교육용 질문의 검색 결과를 확인한 기록입니다

예시 ① 대여 문의

질문: "대여가 안 돼요"
1위: 대여 안내 / 연결과 대여 실패
유사도 약 0.560 · 공개 자료

예시 ② 반납 문의

질문: "반납 알림이 안 와요"
1위: 반납 상태 조회 · 가상 설정
2위: 반납이 완료되지 않을 때

예시 ③ 해외 이용 질문 → 검색 결과 없음(empty)

공개 질문 13개에서 기대 문서·절이 각각 상위 3개에 13/13 포함됐습니다.

시민 모의 요청에서는 제한 문서와 확인 문자열이 각각 0건이었습니다.

※ 검색 근거 결과이며 최종 답변 품질이나 R05 공식 판정은 아닙니다.

출처: runs/public/20261105-093642-local-rag-r05-review/summary.json

08 다음 단계

확인한 내용과 앞으로 시험할 내용을 구분합니다

확인한 내용

VM 수동 색인 44개와 같은 VM의 검색 시험 7건

01 VM 재시작 후 재색인과 검색 복구 확인

02 사용자 조회 → 시민·담당자 검색 권한 연결 시험

03 공식 사례로 최종 답변과 근거 표시 검증

04 PostgreSQL·pgvector 연결, 백업·복구 확인